

**DETEKSI DAN PENCEGAHAN FRAUD INTERNAL DI
PERUSAHAAN MENGGUNAKAN ALGORITMA
RANDOM FOREST DI CV. SMARTINDO
TELEKOM**

**Oleh:
RIYAN SANJAYA
23110036**



**PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS ILMU KOMPUTER DAN TEKNOLOGI INFORMASI
UNIVERSITAS BUDI DARMA
MEDAN
2025**

BAB I

PENDAHULUAN

1.1. Latar Belakang

Dunia bisnis modern, integritas dan kejujuran menjadi fondasi utama bagi keberlanjutan perusahaan. Namun, kasus kecurangan atau fraud internal masih menjadi tantangan serius yang dapat merugikan perusahaan, baik dari segi finansial maupun reputasi. CV. Smartindo Telekom, sebagai perusahaan yang bergerak di bidang Distributor produk telekomunikasi, menghadapi risiko yang sama dalam hal fraud internal. Tercatat sudah banyak dana perusahaan yang digelapkan karyawan. Oleh karena itu, upaya deteksi dan pencegahan fraud menjadi sangat krusial untuk memastikan efisiensi operasional dan menjaga kepercayaan *stakeholder*. Fraud yang dilakukan karyawan terhadap perusahaan perlu diminimalisir karena dapat merusak kepercayaan dan serta menurunkan nilai perusahaan di mata para pemangku kepentingan.

Dalam upaya memahami fenomena kecurangan (fraud) yang terjadi di berbagai institusi, para peneliti telah mengembangkan sejumlah teori untuk menjelaskan motif dan kondisi yang melatarbelakangi tindakan tersebut. Beberapa teori yang umum digunakan antara lain *Fraud Triangle*, *Fraud Diamond*, dan *Fraud Pentagon*, yang masing-masing menjelaskan berbagai faktor pemicu kecurangan dari sudut pandang yang berbeda. Teori *fraud diamond* sangat cocok digunakan pada karena dinilai lebih relevan dengan kondisi nyata di lingkungan perusahaan. Pendekatan ini tidak hanya menyajikan kerangka konseptual yang logis, tetapi juga mencerminkan dinamika kecurangan yang sering terjadi dalam operasional bisnis sehari-hari.

Algoritma *Random Forest* adalah salah satu pendekatan machine learning, yang dikenal efektif dalam mengenali pola-pola anomali pada kumpulan data yang kompleks dan berskala besar. Algoritma ini mampu melakukan klasifikasi secara akurat dengan menggabungkan hasil dari beberapa pohon keputusan (*decision tree*), sehingga menghasilkan prediksi yang lebih stabil dan tahan terhadap overfitting. Kolaborasi antara pendekatan Fraud Diamond dan algoritma Random Forest membuka ruang analisis yang lebih menyeluruh dalam mendeteksi indikasi kecurangan. *Fraud Diamond* membantu memahami motivasi di balik kecurangan melalui empat elemen akan dijadikan variabel yaitu *Pressure* (tekanan), *Opportunity* (kesempatan), *Rationalization* (rasionalisasi), dan *Capability* (kemampuan). Sementara itu, *Random Forest* bekerja dengan memproses variabel tersebut untuk membangun beberapa pohon keputusan, lalu menggabungkan hasilnya agar lebih akurat dan tahan terhadap overfitting.

Berdasarkan penelitian yang telah dilakukan oleh Ravina Armiani tahun 2022, mengaplikasikan *Random Forest* untuk mendeteksi fraud pada transaksi kartu kredit selama pandemi Covid-19. Hasilnya, model *Random Forest* mencapai akurasi 90,68%, presisi 94,74%, recall 86,14%, dan F1 score 90,23%, menunjukkan kemampuan yang sangat baik dalam mendeteksi fraud sehingga dapat mencegah kerugian bagi konsumen dan bank[2]. c menyimpulkan, *Random Forest* dan *XGBoost* pada deteksi penipuan e-commerce. *Random Forest* menunjukkan akurasi 95,35% dan precision 88,68%, namun recall rendah (12,81%) pada dataset asli yang tidak seimbang. Penelitian ini menekankan pentingnya augmentasi data untuk meningkatkan kemampuan deteksi fraud, meskipun Random Forest sudah efektif dalam menangani data kompleks [3]. Pada penelitian Selanjutnya oleh Chengwei Liu pada tahun 2015, menunjukkan bahwa *Random Forest* mampu memberikan akurasi tinggi dalam mendeteksi fraud, bahkan lebih baik dibandingkan beberapa algoritma lain seperti *Logistic Regression* dan SVM. Dimana *Random Forest* dapat mengklasifikasikan perusahaan normal sebagai fraud, sehingga dapat menjaga reputasi perusahaan. [4] . Penelitian Selanjutnya yang dilakukan oleh Fauziah pada tahun 2022, dimana penelitian ini membandingkan kinerja *Random Forest*, *Logistic*

Regression, dan *Gradient Boosting* dalam mendeteksi fraud pada transaksi kartu kredit. *Random Forest* dalam penelitian ini mampu mencapai akurasi hampir sempurna, baik pada data pelatihan maupun pengujian[1]. Berdasarkan penelitian lainnya yang dibuat oleh Gerry William Mathew Kurniawan pada tahun 2025, dimana peneliti mengkaji penggunaan algoritma *Random Forest* untuk mendeteksi penipuan dalam transaksi online yang semakin kompleks dan besar volumenya. Penelitian ini menegaskan bahwa *Random Forest*, dengan penerapan teknik sampling yang tepat, efektif dalam meningkatkan kemampuan sistem mendeteksi dan mencegah penipuan dalam transaksi daring[5]

Berdasarkan uraian yang telah dijabarkan diatas dan referensi penelitian terdahulu, maka penulis akan membuat sebuah judul baru yaitu **“Deteksi dan Pencegahan Fraud Internal di Perusahaan Menggunakan Algoritma Random Forest di CV. Smartindo Telekom”**. Dimana peneliti menggunakan teori *Fraud Diamond* sebagai kerangka kerja konseptual, dan menerapkan algoritma *Random Forest* untuk memprediksi potensi fraud berdasarkan data kuisisioner , skor audit sebelumnya dan lamanya bekerja

1.2. Perumusan Masalah

Berdasarkan latar belakang tersebut, maka perumusan masalah dalam penelitian ini dirumuskan dalam beberapa pertanyaan sebagai berikut:

1. Bagaimana cara mengenali data yang mengindikasikan adanya tindakan fraud internal pada perusahaan berdasarkan kuisisioner yang ada?
2. Bagaimana tipe dan spesifikasi fraud internal dapat diklasifikasikan berdasarkan data yang telah dikumpulkan?
3. Bagaimana penerapan algoritma *Random Forest* dapat membantu dalam mendeteksi fraud?
4. Bagaimana membangun sebuah sistem berbasis website yang mampu menampilkan hasil deteksi fraud dan mempermudah proses monitoring oleh pihak manajemen?

Perumusan masalah tersebut menjadi landasan dalam menentukan metode dan arah penelitian untuk menghasilkan solusi yang tepat guna dalam mendukung upaya pencegahan fraud di lingkungan perusahaan.

1.3. Batasan Masalah

Batasan masalah juga bertujuan untuk menghindari pembahasan yang terlalu luas sehingga hasil penelitian lebih mendalam dan sesuai dengan kebutuhan CV. Smartindo Telekom. Untuk memperjelas fokus kajian dan menghindari keluarnya pembahasan dari jalur yang telah ditetapkan, maka ruang lingkup permasalahan dalam penelitian ini dibatasi sebagai berikut:

- 1) Penelitian ini menggunakan data internal perusahaan yang bersumber dari hasil kuesioner tertutup Juni 2025 kepada karyawan yang bekerja di CV. Smartindo Telekom sebanyak 30 responden.
- 2) Fokus penelitian terbatas pada fraud internal non-finansial, khususnya yang berkaitan dengan potensi fraud berdasarkan data yang diolah dari kuisisioner yang ada.
- 3) Penelitian ini membatasi penggunaan algoritma Random Forest sebagai metode klasifikasi untuk mendeteksi indikasi fraud. Proses yang dilakukan meliputi preprocessing data, training dan testing model, evaluasi performa (akurasi, precision, recall, dan F1-score).
- 4) Penelitian ini menggunakan kerangka teori Fraud Diamond sebagai dasar dalam penyusunan indikator pada kuesioner dan pengelompokan variabel input model. Elemen-elemen Fraud Diamond yang digunakan mencakup Pressure (Tekanan), Opportunity (Kesempatan), Rationalization (Pembenaran), dan Capability (Kemampuan).

Dengan adanya batasan masalah ini, diharapkan penelitian dapat lebih terfokus dan menghasilkan solusi yang efektif serta aplikatif bagi perusahaan.

1.4. Tujuan Penelitian

Fokus utama yang ingin diwujudkan melalui penelitian ini dapat dirinci dalam poin-poin berikut:

- 1) Mengidentifikasi dan menganalisis pola-pola data internal yang berpotensi mengindikasikan terjadinya fraud dalam lingkungan perusahaan.
- 2) Menerapkan teori *Fraud Diamond* sebagai dasar konseptual dalam mengklasifikasikan indikator-indikator penyebab terjadinya fraud.
- 3) Mengembangkan model deteksi fraud berbasis algoritma Random Forest yang mampu mengklasifikasikan apakah suatu data mengandung indikasi fraud atau tidak secara akurat.
- 4) Membangun sistem berbasis website yang dapat menampilkan hasil deteksi fraud secara visual dan interaktif untuk mendukung pengambilan keputusan manajerial.

1.5. Manfaat Penelitian

Melalui penelitian ini, diharapkan dapat diperoleh kontribusi yang berarti, baik dalam ranah pengembangan teori maupun penerapan praktis. Adapun bentuk manfaat yang ingin dicapai dari penelitian ini dijabarkan sebagai berikut:

1. Manfaat bagi Pengguna Sistem (User / Manajemen Perusahaan):
 - a) Memberikan kemudahan dalam mengidentifikasi aktivitas yang berpotensi fraud melalui antarmuka sistem berbasis web yang interaktif.
 - b) Mempercepat proses deteksi kecurangan tanpa harus melakukan audit manual yang memakan waktu dan biaya besar.
2. Manfaat bagi Perusahaan:
 - a) Meningkatkan efektivitas pengawasan internal dengan dukungan sistem yang berbasis data dan kecerdasan buatan.
 - b) Meminimalisir potensi kerugian akibat fraud internal melalui deteksi dini dan tindakan pencegahan yang tepat sasaran.

BAB II

KAJIAN PUSTAKA

2.1. Perusahaan CV. Smartindo Telekom

CV. Smartindo Telekom adalah sebuah perusahaan yang bergerak dibidang distributor telekomunikasi produk dari PT. Smartfren Telcom, dimana perusahaan menawarkan jasa untuk penjualan, retail ke outlet – outlet yang bekerja sama dengan perusahaan. Perusahaan menawarkan produk – produk smartfren ke mitra outlet dan menjaga hubungan baik dengan mitra – mitra outlet tersebut. Perusahaan CV. Smartindo Telekom didirikan oleh Bapak Putra Yudha pada tahun 2015 dan sebagai salah satu mitra distributor dari PT. Smartfren.

2.2.Fraud

Kecurangan (*Fraud*) merupakan tindakan tidak etis yang dilakukan secara sengaja dan sistematis, dengan maksud memperoleh keuntungan pribadi melalui manipulasi atau penyimpangan, yang pada akhirnya merugikan pihak lain secara langsung maupun tidak langsung. Menurut teori Fraud Triangle dari Donald Cressey, fraud bisa terwujud dikarena kombinasi preassure (tekanan), opportunity (kesempatan), dan rationalization (rasionalisasi). Pencegahan fraud dapat dilakukan melalui penguatan pengendalian internal, audit berkala, penggunaan teknologi pemantauan, serta membangun budaya kerja yang menjunjung tinggi integritas dan transparansi.

2.2.1. Fraud Diamond

Fraud Diamond merupakan pengembangan lanjutan dari konsep Fraud Triangle yang awalnya diperkenalkan oleh Donald Cressey. Pada tahun 2004, David T. Wolfe dan Dana R. Hermanson memperluas model ini dengan menambahkan elemen keempat, yaitu Capability (Kemampuan). Model Fraud Diamond terdiri dari empat komponen utama yang saling berhubungan, yaitu: Pressure (Tekanan), Opportunity (Kesempatan), Rationalization (Rasionalisasi), dan Capability (Kemampuan). Tekanan mengacu pada dorongan internal yang membuat seseorang terdorong untuk melakukan kecurangan, yang biasanya berakar dari masalah finansial, beban pekerjaan yang terlalu tinggi, atau kebutuhan pribadi yang mendesak [5]. Selain tekanan, kesempatan juga menjadi faktor kunci. Kesempatan muncul ketika ada kelemahan dalam pengendalian internal, kurangnya pengawasan, atau akses berlebih yang dimiliki individu tertentu. *"Opportunity allows the fraudster to commit the act without being caught, often due to weak controls or lack of oversight"* [5]



Gambar 2.1 Fraud Diamond
Sumber: Wolfe dan Hermanson (2004)

Fraud Diamond juga dapat digunakan sebagai kerangka kerja untuk mendeteksi potensi kecurangan. Berikut beberapa pendekatan yang bisa dilakukan:

- 1) Mendeteksi Tekanan (Pressure)
 - a) Analisis gaya hidup karyawan: Perubahan gaya hidup drastis yang tidak sesuai dengan penghasilan bisa menjadi tanda tekanan finansial.
 - b) Pantau target kerja yang tidak realistis: Tekanan dari target yang terlalu tinggi dapat mendorong karyawan mencari jalan pintas dengan melakukan kecurangan.
 - c) Tinjau konflik pribadi atau profesional: Karyawan yang mengalami masalah pribadi atau konflik dengan perusahaan bisa lebih rentan melakukan kecurangan.
 - d) Cabang mungkin merasa tertekan untuk memenuhi target penjualan atau keuntungan tertentu yang ditetapkan oleh manajemen pusat. Hal ini dapat meningkatkan kemungkinan adanya perilaku kecurangan untuk mencapai target tersebut.
- 2) Menganalisis Kesempatan (Opportunity)
 - a) Evaluasi pengendalian internal: Perusahaan perlu memastikan sistem pengendalian internal kuat dan meminimalkan celah yang bisa dieksploitasi.
 - b) Rotasi kerja dan audit mendadak: Melakukan rotasi posisi karyawan dan audit mendadak dapat mengurangi kesempatan untuk menyembunyikan kecurangan.
 - c) Pemantauan akses dan otorisasi: Pastikan hanya orang dengan otorisasi yang memiliki akses ke sistem keuangan atau data penting.
 - d) Jika kebijakan internal lemah atau laporan keuangan tidak diawasi dengan baik, maka kesempatan untuk melakukan kecurangan meningkat, seperti memanipulasi transaksi atau laporan keuangan.
- 3) Mengidentifikasi Rasionalisasi (Rationalization)
 - a) Kaji budaya etika di perusahaan: Budaya yang mendukung integritas dan kejujuran akan mengurangi kemungkinan karyawan membenarkan tindakan curang.

- b) Pembeneran yang diberikan oleh cabang seperti "untuk memenuhi target" atau "persaingan bisnis" dapat menjadi alasan bagi manajer untuk melakukan kecurangan atau penyalahgunaan.
 - c) Lakukan wawancara atau survei kepuasan kerja: Ketidakpuasan karyawan bisa memicu rasionalisasi. Perusahaan harus memahami alasan di balik ketidakpuasan ini.
- 4) Mengukur Kemampuan (Capability)
 - a) Identifikasi posisi kunci yang rentan: Orang dengan posisi strategis, seperti manajer keuangan atau IT, memiliki potensi lebih besar melakukan kecurangan karena akses dan pengetahuannya.
 - b) Pantau individu dengan pengaruh besar: Karyawan yang memiliki pengaruh besar dan karisma tinggi bisa memanipulasi rekan kerja untuk ikut serta atau menutupi tindakan mereka.
 - c) Perhatikan karyawan dengan keterampilan teknis tinggi: Individu dengan kemampuan teknologi canggih lebih mampu mengeksploitasi celah sistem.
 - d) Kemampuan manajer cabang untuk mengelola operasi dan keuangan cabang dapat menjadi faktor penting dalam menentukan potensi terjadinya kecurangan. Cabang yang memiliki manajer dengan kemampuan rendah atau kurang diawasi lebih rentan terhadap potensi fraud.

2.2.2. Level Fraud pada Jabatan

Fraud (kecurangan) dalam konteks perusahaan cabang bisa terjadi di berbagai level jabatan antara lain sales, admin, dan manajer. Berikut penjelasannya:

a) Fraud oleh Sales

Sales biasanya bertanggung jawab pada penjualan dan hubungan dengan pelanggan. Beberapa jenis kecurangan yang umum dilakukan sales:

- 1) Penggelapan hasil penjualan, dimana sales menerima uang dari pelanggan tetapi hanya melaporkan sebagian atau bahkan tidak melaporkan sama sekali.
- 2) Mark-up harga, dimana menaikkan harga jual di luar ketentuan perusahaan lalu mengambil selisihnya.
- 3) Pemalsuan order, dimana membuat pesanan fiktif untuk mencapai target dan mendapatkan komisi lebih besar.
- 4) Manipulasi diskon atau promo, dimana memberikan diskon tidak sah ke pelanggan dengan imbalan pribadi.

b) Fraud oleh Admin

Admin punya akses ke data dan dokumen penting. Kecurangan yang bisa terjadi di posisi ini:

- 1) Pemalsuan laporan keuangan, memanipulasi data penjualan, pengeluaran, atau stok agar terlihat sesuai target atau menutupi kerugian.
- 2) Penggelapan uang kas kecil dengan Mengambil uang kas dengan membuat kwitansi palsu atau mencatat biaya yang tidak ada.
- 3) Manipulasi stok mencatat barang sudah dikirim padahal belum, lalu menjual barang secara pribadi.

c) Fraud Manajer Cabang

Manajer cabang biasanya punya otoritas lebih besar. Jenis kecurangan yang mungkin dilakukan:

- a) *Kickback* (suap balik) yaitu Kerja sama gelap dengan supplier atau pihak ketiga untuk mendapatkan komisi ilegal.
- b) Manipulasi target dengan Menggelembungkan angka penjualan agar cabang terlihat sukses dan mendapatkan bonus lebih besar.
- c) Rekayasa pengeluaran dengan melaporkan biaya operasional lebih besar dari kenyataan lalu mengambil selisih dana.
- d) Nepotisme atau favoritisme dengan mempekerjakan orang terdekat yang tidak kompeten demi keuntungan pribadi.

2.3. Machine Learning

Machine Learning (ML) adalah salah satu cabang dari kecerdasan buatan (Artificial Intelligence) yang memungkinkan sistem komputer untuk mempelajari pola dari data secara otomatis dan membuat prediksi atau keputusan tanpa harus diprogram secara rinci untuk setiap tugasnya. ML menggunakan berbagai algoritma statistik dan matematika untuk menemukan pola-pola tersembunyi dalam data, yang kemudian diaplikasikan dalam pengambilan keputusan atau prediksi pada data baru. Proses ini biasanya melibatkan tahap pelatihan model dengan menggunakan kumpulan data yang besar agar model dapat memahami hubungan yang kompleks dan pola yang ada.

Proses ML dimulai dengan pengumpulan data yang relevan, kemudian data tersebut diproses dan dibersihkan agar siap digunakan dalam pelatihan model. Selanjutnya, algoritma ML dipilih dan diterapkan untuk melatih model menggunakan data tersebut. Model yang sudah dilatih kemudian diuji dengan data baru untuk mengevaluasi performanya. Jika hasilnya memuaskan, model dapat digunakan untuk prediksi atau klasifikasi dalam aplikasi nyata.

Machine Learning beroperasi dengan cara menganalisis data untuk mengidentifikasi pola serta hubungan matematis antara variabel input dan output. Proses ini diawali dengan pelatihan model menggunakan data yang sudah diberi label (supervised learning) ataupun data yang belum diberi label (unsupervised learning). Setelah pelatihan, model mampu menggeneralisasi pola-pola tersebut sehingga dapat melakukan prediksi atau pengambilan keputusan pada data baru yang belum pernah diproses sebelumnya. Secara sederhana, algoritma ML dilatih dengan contoh input-output, misalnya pasangan data (2,10), (5,19), dan (9,31). Algoritma akan mencari fungsi matematis yang menghubungkan input dan output, seperti $o = 3 \times i + 4$ $o=3 \times i + 4$. Setelah model terlatih, jika diberikan input baru, misalnya 7, model dapat memprediksi outputnya, yaitu 25. Keakuratan prediksi ini bergantung pada kualitas dan kuantitas data yang digunakan selama pelatihan

Jenis - Jenis Machine Learning yang biasa digunakan banyak orang adalah sebagai berikut:

- a) Model Supervised Learning dilatih dengan menggunakan data yang sudah memiliki label, yang berarti setiap data input disertai dengan output yang telah diketahui sebelumnya. Melalui proses ini, model mempelajari hubungan antara input dan output agar dapat memprediksi hasil pada data yang belum pernah ditemui. Contoh penerapannya antara lain adalah klasifikasi email spam dan estimasi harga properti.
- b) Model Unsupervised Learning menggunakan data tanpa label, dengan tujuan utama mengidentifikasi pola, struktur tersembunyi, atau mengelompokkan data menjadi beberapa kategori. Contohnya termasuk segmentasi pelanggan dan identifikasi anomali dalam data.
- c) Model Reinforcement Learning belajar melalui proses interaksi dengan lingkungan di mana model menerima umpan balik berupa hadiah (reward) atau hukuman (penalti). Tujuannya adalah untuk mengoptimalkan pengambilan keputusan agar memperoleh reward sebesar mungkin, dan metode ini sering diterapkan dalam bidang robotika serta pengembangan permainan komputer.

Beberapa algoritma yang sering dipakai dalam Machine Learning adalah berikut ini:

- a) Decision Tree yaitu Algoritma yang memanfaatkan struktur berbentuk pohon untuk mengambil keputusan dengan menganalisis fitur-fitur yang ada pada data.
- b) Random Forest yaitu Kombinasi dari banyak decision tree yang bekerja secara paralel untuk meningkatkan akurasi dan mengurangi overfitting.
- c) Logistic Regression yaitu Sebuah metode statistik yang umum digunakan untuk melakukan klasifikasi dengan dua kategori atau kelas.
- d) Support Vector Machine (SVM) yaitu Algoritma yang berfungsi menentukan garis pemisah (hyperplane) optimal guna membedakan kelompok data yang berbeda.

- e) XGBoost: Algoritma boosting yang efisien dan sering digunakan dalam kompetisi ML karena performanya yang tinggi.

Machine Learning telah banyak diterapkan di berbagai bidang, seperti kesehatan, keuangan, pemasaran, dan lain-lain. Contohnya, dalam bidang kesehatan, ML digunakan untuk memprediksi tingkat kasus penyakit menular, membantu pengambilan keputusan dalam program vaksinasi dan pelayanan kesehatan. Studi yang dilakukan oleh [6] mengaplikasikan beragam algoritma machine learning, termasuk decision tree, random forest, logistic regression, SVM, dan XGBoost, untuk memprediksi tingkat kejadian penyakit di Indonesia. Hasil penelitian ini memberikan dukungan penting bagi para pembuat kebijakan agar dapat merancang kebijakan kesehatan dengan lebih cepat dan tepat.

Selain itu, ML juga digunakan untuk prediksi diagnosis penyakit seperti diabetes menggunakan algoritma neural network yang dioptimasi dengan algoritma evolusi untuk meningkatkan akurasi prediksi [7]. Dalam bidang lain, ML digunakan untuk prediksi ketepatan penempatan karir dengan model klasifikasi seperti Random Forest dan SVM, yang dievaluasi berdasarkan akurasi prediksi [8] [9]. Oleh karena itu machine Learning adalah teknologi yang sangat penting dalam era digital saat ini karena kemampuannya dalam mengolah data besar dan memberikan insight prediktif yang dapat mendukung pengambilan keputusan otomatis dan cepat. Dengan berbagai algoritma yang tersedia, ML dapat disesuaikan untuk berbagai kebutuhan aplikasi, mulai dari klasifikasi, regresi, hingga clustering.

2.3.1. Random Forest

Random Forest merupakan sebuah algoritma machine learning yang termasuk dalam kategori ensemble learning, dimana banyak pohon keputusan (decision tree) digabungkan untuk meningkatkan ketepatan prediksi sekaligus mengurangi kemungkinan overfitting. Algoritma ini dikembangkan oleh Leo

Breiman dan Adele Cutler, dan dapat diterapkan pada berbagai masalah baik klasifikasi maupun regresi.

Random Forest adalah kumpulan pohon keputusan yang masing-masing dibangun dari data dan fitur acak, sehingga menghasilkan model yang kuat dan stabil. Random Forest juga telah digunakan untuk meningkatkan hasil klasifikasi pada deteksi pasien diabetes, dengan akurasi mencapai 95,45% setelah penerapan normalisasi data [9]. Struktur gambar Random Forest adalah representasi visual dari banyak pohon keputusan yang berdiri sendiri, dengan proses agregasi hasil sebagai komponen penting dalam menghasilkan prediksi akhir. Random Forest merupakan salah satu algoritma klasifikasi yang banyak digunakan karena mampu menghasilkan prediksi dengan akurasi tinggi, seperti yang dibuktikan pada penelitian klasifikasi cuaca dan banjir di Indonesia [10].


Random Forest menciptakan sejumlah besar pohon keputusan dengan menggunakan teknik bootstrap sampling dan pemilihan fitur secara acak untuk meningkatkan presisi sekaligus mengurangi risiko overfitting. Setiap pohon terdiri dari struktur decision tree yang meliputi root node, node internal, cabang, dan daun yang menghasilkan prediksi. Hasil akhir ditentukan melalui mekanisme voting mayoritas pada kasus klasifikasi atau rata-rata pada kasus regresi dari semua pohon yang tergabung dalam model.

Pada Random Forest, setiap pohon dibangun dengan data bootstrap sampling dan pada setiap split hanya dipertimbangkan subset acak fitur, sehingga pohon-pohon yang terbentuk berbeda dan tidak berkorelasi tinggi. Namun, proses pembentukan pohon pada masing-masing decision tree tetap mengikuti prinsip di atas, yaitu mencari fitur terbaik berdasarkan kriteria seperti Gini atau Entropy untuk memisahkan data secara rekursif hingga mencapai kondisi berhenti.

Selain bootstrap sampling, Random Forest juga menerapkan random feature selection pada setiap node split dalam decision tree. Alih-alih

mempertimbangkan semua fitur, algoritma hanya memilih subset fitur secara acak untuk menentukan split terbaik. Hal ini menurunkan korelasi antar pohon dan meningkatkan keragaman model sehingga mengurangi varians dan risiko overfitting.

Struktur dan komponen Random Forest dapat dipahami sebagai kumpulan (ensemble) dari banyak pohon keputusan (decision trees) yang bekerja secara paralel dan independen, Selanjutnya, hasil dari setiap pohon tersebut digabungkan untuk menghasilkan prediksi akhir yang lebih tepat dan konsisten. Berikut ini adalah ilustrasi struktur dari algoritma Random Forest:



Gambar 3.2 Struktur dan komponen Random Forest

Sumber: Minrui Zheng dkk (2020)

Berikut ini adalah penjabaran secara sederhana dan singkat dengan flowchart sederhana pada algoritma random forest ialah:

- 1) Mulai
- 2) Ambil dataset asli

- 3) Lakukan bootstrap sampling (ambil sampel acak dengan pengembalian dari dataset asli untuk membuat beberapa subset data)
- 4) Bangun decision tree untuk setiap subset data
 - a) Pada setiap node, pilih subset fitur secara acak
 - b) Tentukan split terbaik berdasarkan fitur yang dipilih
 - c) Bangun pohon sampai kriteria penghentian tercapai (misal max depth atau node minimum)
- 5) Ulangi langkah 3-4 untuk membentuk banyak pohon (n_trees)
- 6) Untuk data baru, lakukan prediksi dengan setiap pohon
- 7) Gabungkan hasil prediksi dari semua pohon
 - a) Untuk klasifikasi: voting mayoritas
 - b) Untuk regresi: rata-rata prediksi
- 8) Output hasil prediksi akhir
- 9) Selesai

Berikut adalah langkah – langkah algoritma Random Forest secara lengkap adalah sebagai berikut:

a) Bootstrap Sampling

Bootstrap sampling dalam Random Forest adalah proses pengambilan sampel acak dari dataset asli dengan pengembalian (sampling dengan replacement) untuk membentuk beberapa subset data yang masing-masing digunakan untuk melatih satu pohon keputusan secara independen. Ini berarti beberapa data dapat terpilih lebih dari satu kali dalam satu subset, sementara beberapa data lain mungkin tidak terpilih sama sekali. Cara kerja dari bootstrap sampling dalam random forest adalah sebagai berikut:

- 1) Dari dataset pelatihan yang tersedia, dilakukan pengambilan sampel secara acak dengan pengembalian untuk membentuk subset data baru yang berukuran sama dengan dataset asli.
- 2) Setiap subset ini menjadi data latih untuk satu pohon keputusan dalam hutan acak. Karena adanya pengembalian, setiap pohon mendapatkan data yang sedikit berbeda, menciptakan variasi antar pohon.

- 3) Variasi ini penting untuk mengurangi korelasi antar pohon dan menghindari overfitting, sehingga hasil agregasi prediksi menjadi lebih stabil dan akurat.
- 4) Selain itu, sekitar sepertiga data yang tidak terpilih dalam bootstrap disebut out-of-bag (OOB), yang bisa digunakan untuk validasi model tanpa perlu data terpisah

Misal dataset asli berisi 1000 sampel. Dengan bootstrap sampling, untuk setiap pohon diambil 1000 sampel secara acak dengan pengembalian. Jadi, satu pohon mungkin memiliki 700 sampel unik, dan 300 sampel terduplikasi, sementara 300 lainnya tidak terpilih. Pohon lain akan memiliki subset yang berbeda, sehingga menghasilkan model yang lebih robust saat hasilnya digabungkan. Dengan demikian, bootstrap sampling adalah fondasi penting dalam Random Forest yang memungkinkan pembentukan banyak pohon keputusan yang berbeda dan meningkatkan performa model secara keseluruhan

b) Pembentukan Decision Tree

Pembentukan Decision Tree adalah proses konstruksi pohon keputusan yang dimulai dari root node (akar) yang berisi seluruh dataset, kemudian secara rekursif membagi data menjadi subset-subset yang lebih homogen berdasarkan fitur terbaik yang dipilih pada setiap langkah pemisahan (splitting). Proses ini terus berlangsung sampai memenuhi kondisi penghentian tertentu, seperti ketika semua data dalam subset tergolong ke dalam kelas yang seragam, kedalaman pohon telah mencapai batas maksimal, atau jumlah data dalam subset menjadi terlalu sedikit untuk diproses lebih lanjut. Berikut ini adalah langkah – langkah pembentukan pohon keputusan secara detail yaitu:

1) Mulai dari Root Node

Seluruh data pelatihan berada pada root node

2) Pemilihan Fitur Terbaik untuk Memisahkan Data (Splitting)

Pada setiap node, algoritma mencari fitur dan nilai ambang (threshold) yang paling efektif untuk membagi data menjadi subset yang lebih

homogen terhadap target kelas. Kriteria pemilihan fitur biasanya menggunakan metrik:

a) Gini Impurity

$$Gini(t) = 1 - \sum_{i=1}^c p_i^2 \dots \dots \dots (1)$$

di mana p_i merepresentasikan proporsi kelas ke- i pada node t . Semakin rendah nilai Gini, maka tingkat kemurnian node tersebut semakin tinggi.

b) Entropy dan Information Gain:

$$Entropy(t) = - \sum_{i=1}^c p_i \log_2 p_i \dots \dots \dots (2)$$

Information Gain adalah pengurangan entropy setelah pemisahan:

$$IG = Entropy(parent)$$

$$- \sum_k \frac{N_k}{N} Entropy(k) \dots \dots \dots (3)$$

di mana k adalah subset hasil pemisahan, N_k jumlah sampel di subset, dan N jumlah sampel di parent node. Algoritma memilih fitur dan threshold dengan nilai Gini terendah atau Information Gain tertinggi.

c) Membagi Data ke Subset Berdasarkan Fitur Terpilih

Data dibagi ke cabang-cabang baru sesuai dengan hasil pengujian fitur (misalnya, nilai fitur $\leq$ threshold ke cabang kiri, $>$ threshold ke cabang kanan).

d) Rekursi pada Subset Data

Proses pemilihan fitur dan pembagian data diulang pada setiap node anak yang baru terbentuk.

e) Kriteria Berhenti

Proses pembentukan pohon berhenti jika:

1. Seluruh data pada node tersebut termasuk dalam satu kelas yang identik (node yang homogen) .

2. Pohon telah mencapai tingkat kedalaman maksimum yang telah ditetapkan sebelumnya.
3. Jumlah data dalam node kurang dari batas minimum.
4. Tidak ada peningkatan signifikan dalam pemisahan data.

f) Penentuan Label pada Node Daun (Leaf Node)

Pada node daun, kelas yang dipilih biasanya adalah kelas mayoritas dari data yang berada di node tersebut (untuk klasifikasi), atau rata-rata nilai target (untuk regresi).

Decision tree dimulai dari root dan membandingkan nilai fitur untuk menelusuri cabang hingga mencapai simpul daun. Algoritma memilih fitur terbaik berdasarkan metrik seperti Gini Impurity, Entropy, dan Information Gain untuk memisahkan data secara rekursif. Setiap node internal berisi kondisi uji atribut, dan daun merepresentasikan kelas target [11]. Random Forest membangun banyak decision tree dengan subset data dan fitur acak untuk mengurangi korelasi antar pohon. Dengan demikian, pembentukan decision tree adalah proses rekursif pemilihan fitur terbaik untuk memisahkan data secara bertingkat, menghasilkan struktur pohon yang dapat digunakan untuk klasifikasi atau regresi.

c) Prediksi Setiap Pohon

Setelah pohon terbentuk, setiap pohon memberikan prediksi untuk data baru. Untuk klasifikasi, pohon memberikan kelas; untuk regresi, pohon memberikan nilai numerik.

d) Voting atau Averaging untuk Prediksi Akhir

Setelah itu, untuk klasifikasi, prediksi akhir diambil berdasarkan voting mayoritas dari hasil prediksi semua pohon (kelas yang paling banyak dipilih). Pada regresi, prediksi akhir adalah rata – rata dari semua pohon. Rumus prediksi regresi Random Forest antara lain:

$$\tilde{y} = \frac{1}{N} \sum_{i=1}^N h_i x \dots \dots \dots (4)$$

Dimana:

$\hat{y}$ = prediksi akhir

N = total pohon yang ada dalam hutan

$h_i x$ = prediksi yang dihasilkan oleh pohon ke- i untuk input x

2.3.2. Metrik Evaluasi Klasifikasi

Ada empat metrik evaluasi utama yang sering digunakan dalam klasifikasi, termasuk pada model seperti Random Forest: Accuracy, Precision, Recall, dan F1-Score, berikut adalah empat metrik evaluasi:

a) Accuracy

Accuracy merupakan salah satu metrik yang paling sering dipakai untuk menilai kemampuan sebuah model dalam mengklasifikasikan data secara keseluruhan. Nilai accuracy dihitung dari perbandingan antara jumlah prediksi yang tepat (true positive ditambah true negative) dengan total data yang dianalisis. Dengan kata lain, akurasi menggambarkan seberapa besar persentase prediksi yang benar dari seluruh prediksi yang dibuat oleh model.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \dots \dots \dots (5)$$

Accuracy cocok digunakan jika distribusi kelas positif dan negatif pada dataset seimbang. Namun, jika dataset tidak seimbang (misal, data positif jauh lebih sedikit dari negatif), accuracy bisa menyesatkan karena model bisa saja mendapatkan nilai accuracy tinggi hanya dengan memprediksi mayoritas kelas saja.

b) Precision

Precision menunjukkan tingkat ketepatan model dalam memprediksi kelas positif. Nilai precision dihitung sebagai perbandingan antara jumlah prediksi

positif yang benar (true positive) dengan keseluruhan prediksi positif yang dilakukan (true positive ditambah false positive).

$$\text{Precision} = \frac{\text{True Postive}}{\text{True Postive} + \text{False Positive}} \dots \dots \dots (6)$$

Precision penting untuk meminimalkan prediksi positif yang salah (false positive), misalnya pada deteksi spam, di mana kita ingin memastikan email yang diklasifikasikan sebagai spam benar-benar spam.

c) Recall

Recall, yang juga dikenal sebagai sensitivity, menilai kemampuan model dalam mengidentifikasi seluruh data positif dengan tepat. Recall dihitung sebagai perbandingan antara jumlah prediksi positif yang benar (true positive) dengan total data yang memang benar positif (true positive ditambah false negative). Tujuannya adalah untuk meminimalkan jumlah kesalahan berupa false negative.

$$\text{Recall} = \frac{\text{True Postive}}{\text{True Postive} + \text{False Negative}} \dots \dots \dots (7)$$

d) F1-Score

F1-score merupakan ukuran evaluasi yang menggabungkan precision dan recall dalam satu nilai dengan menggunakan rata-rata harmonis. Metrik ini sangat berguna untuk mengevaluasi performa model pada data yang tidak seimbang, karena memberikan penilaian yang seimbang antara ketepatan dan kemampuan model dalam menangkap seluruh kasus positif.

$$\text{F1-score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \dots \dots \dots (7)$$

F1-score akan memberikan gambaran yang lebih baik tentang performa model jika ingin memperhatikan baik precision maupun recall secara bersamaan.

2.4. Google Form

Google Forms merupakan alat berbasis web yang sangat efektif untuk membuat dan menyebarkan kuisisioner secara online. Ketika responden mengisi kuisisioner, data secara otomatis tersimpan dan terorganisir dalam Google Sheets, yaitu spreadsheet online yang terintegrasi langsung dengan Google Forms. Data yang masuk dari Google Forms langsung tersimpan rapi dalam Google Sheets tanpa perlu input manual, menghemat waktu dan mengurangi kesalahan.

2.5. Google Sheets

Google Sheets merupakan layanan spreadsheet berbasis daring yang memfasilitasi pengguna dalam menyusun, memodifikasi, serta mengatur data dalam bentuk tabel terdiri atas baris dan kolom, dengan akses yang dapat dilakukan secara real-time melalui internet. Berbeda dengan software spreadsheet tradisional seperti Microsoft Excel yang berbasis offline, Google Sheets menyimpan data secara otomatis di cloud sehingga data dapat diakses dan dikerjakan secara real-time dari berbagai perangkat yang terhubung internet. Fungsi utama dari google sheet adalah:

- a) Pengolahan Data: Memungkinkan pengurutan, manipulasi, dan kalkulasi data menggunakan rumus matematika dan fungsi statistik
- b) Visualisasi Data: Mendukung pembuatan grafik dan diagram yang membantu dalam analisis data dan pelaporan
- c) Integrasi dengan Google Forms: Data hasil pengisian kuisisioner Google Forms otomatis tersimpan di Google Sheets, memudahkan pengelolaan dan analisis data survei.
- d) Penyimpanan Otomatis: Data tersimpan secara otomatis di cloud sehingga mengurangi risiko kehilangan data akibat gangguan perangkat

2.6. VS Code

Visual Studio Code (VS Code) adalah editor kode sumber buatan Microsoft yang ringan namun kaya fitur, mendukung berbagai bahasa pemrograman, termasuk Dart dan Python. VS Code dilengkapi dengan IntelliSense untuk memberikan saran kode yang cerdas, debugger bawaan untuk membantu menemukan dan memperbaiki error, serta integrasi Git agar lebih mudah mengelola versi kode. Selain itu, tersedia banyak ekstensi yang bisa diinstal, seperti Flutter untuk pengembangan aplikasi Dart dan Python extension yang mendukung analisis kode, virtual environment, hingga Jupyter Notebook. Kombinasi fitur ini menjadikan VS Code pilihan populer bagi pengembang aplikasi.

2.7. Website

Sebuah website (situs web) adalah kumpulan halaman web yang saling terkait dan konten multimedia seperti gambar, audio, dan video, yang dapat diakses publik melalui internet menggunakan browser web. Secara sederhana, bayangkan website sebagai sebuah buku. Setiap halaman dalam buku adalah sebuah "halaman web", dan semua halaman ini terikat bersama di bawah satu nama (domain) yang disebut "website". Buku ini disimpan di tempat yang bisa diakses oleh siapa saja di dunia (server web), dan Anda bisa membacanya menggunakan alat bantu (browser web seperti Chrome, Firefox, atau Safari). Berikut adalah beberapa komponen kunci dari sebuah website:

- a) Halaman Web adalah dokumen yang ditulis dalam bahasa HTML (HyperText Markup Language) yang berisi teks, gambar, video, dan tautan.
- b) Browser Web adalah perangkat lunak seperti Google Chrome, Mozilla Firefox, Microsoft Edge, atau Apple Safari yang digunakan untuk menampilkan halaman web.
- c) Server Web adalah komputer khusus yang menyimpan file-file website dan mengirimkannya ke browser web saat diminta.

- d) Nama Domain adalah alamat unik dari sebuah website di internet, contohnya google.com atau detik.com. Ini seperti alamat rumah untuk website Anda.
- e) Hosting adalah layanan yang menyediakan ruang di server web untuk menyimpan file-file website Anda agar dapat diakses secara online.
- f) Website dapat memiliki berbagai tujuan, mulai dari situs pribadi, blog, toko online, portal berita, media sosial, hingga aplikasi web yang kompleks.

2.8. Bahasa Pemrograman Python

Python merupakan salah satu bahasa pemrograman yang banyak diminati karena struktur sintaksnya yang ringkas dan intuitif, sehingga cocok digunakan baik oleh pemula maupun programmer berpengalaman. Bahasa ini mendukung beragam pendekatan pemrograman, mulai dari paradigma objek, prosedural, hingga fungsional. Penerapannya sangat luas, mencakup pengembangan aplikasi web, analisis data, kecerdasan buatan, hingga proses otomasi berbagai tugas digital. Python memiliki pustaka (library) yang sangat kaya, seperti Django dan Flask untuk web, Pandas dan NumPy untuk analisis data, serta TensorFlow untuk machine learning. Kemampuan Python yang fleksibel serta dukungan dari komunitas global yang aktif menjadikannya sebagai salah satu bahasa pemrograman yang paling banyak digunakan di seluruh dunia.

2.9. Framework Flask

Flask adalah sebuah micro-framework web untuk bahasa pemrograman Python. Istilah "micro" merujuk pada inti yang minimalis namun sangat fleksibel dan dapat diperluas. Ia tidak memaksakan struktur proyek atau menyediakan banyak fitur bawaan, melainkan memberi kebebasan penuh kepada pengembang untuk memilih komponen dan pustaka yang mereka inginkan. Ini menjadikannya pilihan ideal untuk membangun aplikasi web kecil hingga menengah, API RESTful, atau untuk tujuan pembelajaran pengembangan web dengan Python.

2.10. Unified Modeling Language (UML)

Unified Modeling Language (UML) merupakan bahasa standar yang digunakan untuk menggambarkan sistem secara visual, terutama pada sistem yang berorientasi objek. UML berperan sebagai alat bantu penting dalam proses perancangan, visualisasi, dokumentasi, serta pengembangan sistem perangkat lunak maupun sistem kompleks lainnya. UML membantu menggambarkan bagaimana sebuah sistem bekerja melalui berbagai diagram yang menjelaskan struktur dan perilaku sistem tersebut secara terperinci. Sistem dirancang menggunakan pemodelan diagram UML untuk menggambarkan kebutuhan sistem dan pekerjaan yang dapat diselesaikan [12].

UML pertama kali dikembangkan oleh Object Management Group (OMG) dan versi awalnya dirilis pada tahun 1997. UML menjadi bahasa pemodelan yang sangat penting dalam rekayasa perangkat lunak karena dapat mempermudah komunikasi antara pengembang sistem dan pengguna, serta memfasilitasi proses pengembangan perangkat lunak yang berkelanjutan. Fungsi utama dan tujuan penggunaan UML adalah sebagai berikut:

- a) Memvisualisasikan sistem dari UML menyediakan diagram yang memudahkan pemahaman sistem secara keseluruhan dan bagian-bagiannya.
- b) Mendokumentasikan sistem dengan UML membantu mendokumentasikan kebutuhan, desain, dan arsitektur sistem sehingga memudahkan pengembangan dan pemeliharaan.
- c) Membantu analisis dan perancangan, UML digunakan untuk menganalisis kebutuhan sistem dan merancang solusi yang tepat sebelum implementasi coding.
- d) Memfasilitasi komunikasi dan menjadi jembatan antara pengembang dan pengguna sistem, sehingga kebutuhan pengguna dapat diterjemahkan dengan jelas ke dalam desain sistem

Komponen – komponen yang terdapat pada diagram UML adalah sebagai berikut ini:

- a) Use Case Diagram dapat menjelaskan hubungan antara pengguna (aktor) dengan sistem, serta menggambarkan fungsi-fungsi utama yang disediakan oleh sistem tersebut.
- b) Class Diagram dapat memvisualisasikan struktur kelas dalam sistem, lengkap dengan atribut dan metode yang melekat pada masing-masing kelas.
- c) Activity Diagram dapat mengilustrasikan alur kerja atau proses bisnis yang terjadi dalam sistem secara rinci.
- d) Sequence Diagram dapat menggambarkan interaksi antar objek dalam urutan kronologis selama proses berlangsung,
- e) Diagram lainnya seperti State Diagram, Component Diagram, dan Deployment Diagram juga sering digunakan sesuai kebutuhan sistem

UML adalah bahasa pemodelan visual yang esensial dalam perancangan sistem berorientasi objek. Dengan UML mempermudah proses analisis, desain, dokumentasi, dan komunikasi dalam pengembangan perangkat lunak. Diagram UML seperti Use Case, Class, Activity, dan Sequence sangat berguna untuk menggambarkan kebutuhan dan desain sistem secara jelas.

2.11. Metode dan Tahapannya

Dalam penelitian ini, digunakan metode kuantitatif, yaitu pendekatan yang memanfaatkan data numerik dan teknik statistik untuk mengumpulkan serta mengolah data yang dapat diukur secara objektif. Metode ini bertujuan untuk memberikan penjelasan, melakukan prediksi, atau mengendalikan fenomena tertentu melalui pendekatan eksperimen. Fokus utama adalah membangun model deteksi dan pencegahan fraud internal di CV. Smartindo Telekom menggunakan algoritma Random Forest, dengan pendekatan analisis berdasarkan kerangka Fraud Diamond.

2.11.1. Pengumpulan Data

Proses pengumpulan data dalam penelitian ini bertujuan untuk mengumpulkan informasi yang relevan mengenai faktor-faktor dalam model Fraud Diamond, serta data historis yang berkaitan dengan aktivitas internal di CV. Smartindo Telekom. Data yang dikumpulkan terdiri dari dua kategori, yaitu:

- a) Data Primer adalah data yang diperoleh melalui penyebaran kuesioner kepada karyawan perusahaan untuk mengukur aspek tekanan (pressure), peluang (opportunity), rasionalisasi (rationalization), dan kemampuan (capability). Kuesioner tersebut disusun berdasarkan indikator yang mewakili keempat komponen utama Fraud Diamond.
- b) Data Sekunder dimana meliputi data historis aktivitas keuangan, catatan transaksi penjualan, laporan audit internal, serta catatan pelanggaran atau dugaan fraud yang pernah terjadi. Data ini digunakan untuk membangun model prediksi dan pelatihan algoritma Random Forest.

Proses pengumpulan data dilakukan secara sistematis agar hasil analisis dapat merepresentasikan kondisi aktual perusahaan dan mendukung pengembangan model deteksi serta pencegahan fraud secara akurat.

2.11.2. Variabel Pada Penelitian dan Indikator

Penelitian ini mengadopsi variabel-variabel yang dirancang berdasarkan kerangka Fraud Diamond, yang mencakup empat komponen utama, yaitu Pressure, Opportunity, Rationalization, dan Capability. Masing-masing komponen tersebut diwakili oleh beberapa indikator yang dikembangkan menjadi pertanyaan dalam kuesioner serta fitur pada dataset yang digunakan dalam model algoritma Random

Skala Likert merupakan teknik pengukuran yang sering dipakai dalam penelitian untuk menilai sikap, opini, atau pandangan individu terhadap suatu

pernyataan atau topik tertentu. Metode ini menggunakan rangkaian pernyataan yang disertai pilihan jawaban berjenjang, contohnya seperti "Sangat Setuju", "Setuju", "Netral", "Tidak Setuju", hingga "Sangat Tidak Setuju". Berdasarkan [13], skala Likert digunakan untuk mengukur sikap, pandangan, serta persepsi individu atau kelompok terhadap suatu fenomena sosial. Pilihan jawaban dalam skala ini disusun secara bertingkat untuk menangkap intensitas respon yang diberikan.

2.11.3. Teknik Pada Analisis Data

Proses analisis data pada penelitian ini dilaksanakan secara sistematis dengan tujuan mengembangkan model deteksi serta pencegahan kecurangan internal menggunakan algoritma Random Forest, yang didasarkan pada konsep Fraud Diamond. Tahapan analisis data meliputi beberapa proses berikut:

a) Pra-Pemrosesan Data

Sebelum dilakukan analisis, data yang dikumpulkan melalui kuesioner dan data sekunder terlebih dahulu diproses agar siap digunakan dalam pelatihan model. Tahapan pra-pemrosesan data meliputi:

1. Data cleaning, yaitu mengeliminasi data yang duplikat, mengisi nilai yang hilang (missing value), serta menghapus data pencilan (outlier) bila diperlukan
2. Transformasi data, yaitu mengkonversi data kualitatif seperti skala Likert menjadi format numerik.
3. Normalisasi/standardisasi: Menyesuaikan skala nilai antar variabel agar seragam, jika diperlukan untuk meningkatkan performa algoritma.
4. Labeling: Memberikan label fraud (1) atau tidak fraud (0) berdasarkan data audit atau hasil validasi dari manajemen.

b) Pembentukan Dataset

Setelah melewati proses pra-pemrosesan, data kemudian dipisah menjadi dua bagian yaitu:

1. Data Latih (Training Set), yang berfungsi untuk melatih model Random Forest.
2. Data Uji (Testing Set), yang digunakan untuk mengukur dan menilai kinerja model dalam mendeteksi fraud.

c) Implementasi Algoritma Random Forest

Random Forest merupakan metode klasifikasi yang mengandalkan prinsip ensemble learning dengan menggabungkan banyak pohon keputusan untuk memperoleh hasil prediksi yang lebih akurat. Algoritma ini dipilih karena efektivitasnya dalam mengelola data yang kompleks dan multivariat serta kemampuannya dalam mengidentifikasi fitur-fitur kunci yang berperan signifikan dalam mendeteksi fraud. Tahapan implementasi model ini dijelaskan sebagai berikut:

1. Melatih model dengan parameter yang telah ditentukan.
2. Melakukan validasi model menggunakan cross-validation atau confusion matrix.
3. Mengukur performa model dengan metrik seperti:
 - a. Accuracy (akurasi)
 - b. Precision (ketepatan)
 - c. Recall (sensitivitas)
 - d. F1-Score

2.12. Penelitian Terkait

Untuk lebih dalam memahami dan mempelajari tentang random forest, penulis akan memberikan lima penelitian terkait sebagai bahan referensi untuk penulisan skripsi ini antara lain adalah:

- 1) Penelitian yang dilakukan oleh Ravina Armiani tahun 2022, yang membahas tentang Analisa Fraud pada Transaksi Kartu Kredit menggunakan Random Forest, Penelitian ini mengaplikasikan Random Forest untuk mendeteksi fraud pada transaksi kartu kredit selama pandemi Covid-19. Hasilnya, model Random Forest mencapai akurasi 90,68%,

presisi 94,74%, recall 86,14%, dan F1 score 90,23%, menunjukkan kemampuan yang sangat baik dalam mendeteksi fraud sehingga dapat mencegah kerugian bagi konsumen dan bank [3].

- 2) Penelitian selanjutnya dibuat oleh Ravina Armiani tahun 2022 yang membahas, Performa Random Forest dan XGBoost pada Deteksi Penipuan E-Commerce dengan Augmentasi Data CGAN. Penelitian ini mengevaluasi Random Forest dan XGBoost pada deteksi penipuan e-commerce. Random Forest menunjukkan akurasi 95,35% dan precision 88,68%, namun recall rendah (12,81%) pada dataset asli yang tidak seimbang. Penelitian ini menekankan pentingnya augmentasi data untuk meningkatkan kemampuan deteksi fraud, meskipun Random Forest sudah efektif dalam menangani data kompleks [4]
- 3) Pada penelitian Selanjutnya oleh Chengwei Liu pada tahun 2015, yang membahas tentang Financial Fraud Detection Model Based on Random Forest. Penelitian ini menunjukkan bahwa Random Forest mampu memberikan akurasi tinggi dalam mendeteksi fraud, bahkan lebih baik dibandingkan beberapa algoritma lain seperti Logistic Regression dan SVM. Kelebihan utama dari penelitian ini adalah kemampuannya meminimalkan kesalahan tipe II, yaitu mengklasifikasikan perusahaan normal sebagai fraud, sehingga dapat menjaga reputasi perusahaan. [1]
- 4) Penelitian Selanjutnya yang dilakukan oleh Fauziah pada tahun 2022, yang membahas tentang Fraud Detection Using Random Forest Classifier, Logistic Regression, and Gradient Boosting Classifier Algorithms on Credit Cards. Penelitian ini membandingkan kinerja Random Forest, Logistic Regression, dan Gradient Boosting dalam mendeteksi fraud pada transaksi kartu kredit. Kelebihan penelitian ini terletak pada penggunaan teknik SMOTE untuk mengatasi ketidakseimbangan data, sehingga model yang dihasilkan menjadi lebih andal dan akurat. Random Forest dalam penelitian ini mampu mencapai akurasi hampir sempurna, baik pada data pelatihan maupun pengujian [2].


- 5) Berdasarkan penelitian lainnya yang dibuat oleh Gerry William Mathew Kurniawan pada tahun 2025, yang membahas tentang Pendeteksian Penipuan Menggunakan Pendekatan Metode Klasifikasi Random Forest. Penelitian ini mengkaji penggunaan algoritma Random Forest untuk mendeteksi penipuan dalam transaksi online yang semakin kompleks dan besar volumenya. Penelitian ini menegaskan bahwa Random Forest, dengan penerapan teknik sampling yang tepat, efektif dalam meningkatkan kemampuan sistem mendeteksi dan mencegah penipuan dalam transaksi daring [5].

BAB III

METODELOGI PENELITIAN

3.1. Kerangka Kerja Penelitian

Kerangka kerja penelitian ini dirancang untuk memberikan gambaran sistematis mengenai tahapan-tahapan dalam penerapan algoritma Random Forest guna mendeteksi potensi fraud pada setiap cabang perusahaan. Dibawah ini adalah desain dari kerangka kerjanya yaitu:



Gambar 3.1 Desain kerangka kerja penelitian.

1) Penyusunan Instrumen dan Pengumpulan Data

Instrumen penelitian yang digunakan dalam studi ini berupa kuesioner tertutup tiap cabang yang disusun berdasarkan empat elemen utama dari teori Fraud Diamond yang dikemukakan oleh Wolfe dan Hermanson, yaitu: Pressure (tekanan), Opportunity (kesempatan), Rationalization (pembenaran), dan Capability (kemampuan). Setiap elemen terdiri dari beberapa indikator yang kemudian dijabarkan dalam bentuk pernyataan untuk dijawab oleh responden menggunakan skala Likert 5 poin, mulai dari 1 (Sangat Tidak Setuju) hingga 5 (Sangat Setuju).

a) Elemen Pressure (Tekanan)

Elemen ini mencerminkan tekanan yang mungkin dirasakan karyawan, baik dalam aspek ekonomi maupun target kerja. Indikator yang digunakan meliputi kebutuhan ekonomi yang mendesak, target kerja yang tinggi dan sulit dicapai, beban utang pribadi, tekanan finansial dalam pekerjaan, dan keinginan untuk mencari penghasilan tambahan. Pernyataan yang diberikan dalam kuesioner antara lain:

Table 3.1 Pertanyaan Bagian Elemen Pressure

No	Pernyataan	Skor (1–5)
P1	Saya memiliki kebutuhan ekonomi yang besar.	
P2	Target kerja yang dibebankan kepada saya sangat sulit dicapai.	
P3	Saya memiliki tanggungan atau utang pribadi yang cukup besar.	
P4	Saya merasa tertekan secara finansial dalam menjalani pekerjaan ini.	
P5	Saya merasa perlu mencari cara tambahan untuk menambah penghasilan.	

b) Elemen Opportunity (Kesempatan):

Elemen ini berkaitan dengan adanya peluang untuk melakukan kecurangan yang disebabkan oleh lemahnya pengawasan atau celah dalam sistem internal perusahaan. Indikator yang diukur meliputi lemahnya sistem pengawasan, adanya celah dalam prosedur kerja, minimnya pemantauan terhadap karyawan, ketidakkonsistenan dalam penegakan aturan, serta pengetahuan responden tentang bagaimana menghindari deteksi. Contoh pernyataannya:

Table 3.2 Pertanyaan Bagian Elemen Opportunity

No	Pernyataan	Skor (1–5)
O1	Prosedur pengawasan di tempat saya bekerja masih lemah.	
O2	Ada celah dalam sistem kerja yang memungkinkan manipulasi data.	
O3	Saya merasa tindakan saya jarang dipantau atau diawasi.	
O4	Aturan internal perusahaan jarang ditegakkan secara konsisten.	
O5	Saya tahu cara cenderung tidak mengikuti SOP perusahaan	

c) Elemen Rationalization (Pembenaran):

Elemen ini mengukur sejauh mana seseorang membenarkan secara pribadi tindakannya dalam melakukan kecurangan. Indikator dalam bagian ini mencakup anggapan bahwa kecurangan kecil tidak berdampak besar, pembenaran karena merasa kurang dihargai, adanya persepsi bahwa banyak orang lain juga melakukan hal yang sama, serta merasa berhak atas kompensasi tambahan. Pernyataan dalam kuesioner antara lain:

Table 3.3 Pertanyaan bagian Elemen Rationalization

No	Pernyataan	Skor (1–5)

R1	Saya pernah berpikir bahwa kecurangan kecil tidak masalah.	
R2	Saya merasa wajar jika mengambil sesuatu dari perusahaan jika saya merasa kurang dihargai.	
R3	Banyak orang juga melakukan hal yang sama (kecurangan).	
R4	Selama tidak ketahuan, saya pikir itu bukan masalah besar.	
R5	Saya merasa berhak atas kompensasi tambahan atas kerja keras saya.	

d) Elemen Capability (Kemampuan):

Elemen ini menilai sejauh mana seorang individu memiliki kapasitas dan kemampuan untuk melakukan kecurangan, termasuk dari segi teknis, pengalaman, dan kewenangan. Indikator yang digunakan mencakup pengetahuan tentang sistem kerja dan kelemahannya, akses terhadap sistem atau aset penting, kemampuan untuk melakukan tindakan tanpa diketahui, serta kemampuan untuk memengaruhi atau memanipulasi orang lain. Contoh pernyataannya adalah:

Table 3.4 Pertanyaan Bagian Elemen Capability

No	Pernyataan	Skor (1–5)
C1	Saya memahami sistem kerja dan bisa menemukan celah di dalamnya.	
C2	Saya memiliki wewenang untuk mengakses administrasi atau aset penting perusahaan.	

C3	Saya merasa mampu melakukan tindakan manipulatif tanpa diketahui.	
C4	Saya tahu siapa saja di perusahaan yang dapat saya manfaatkan untuk menutupi kesalahan.	
C5	Saya merasa cukup berpengalaman untuk melakukan sesuatu di luar prosedur standar.	

Berikut penjelasan masing-masing variabel tambahan berdasarkan elemen Fraud Diamond yaitu:

- a) Pengalaman Kerja dimana variabel ini mengukur lamanya masa kerja responden di perusahaan dalam satuan tahun. Semakin lama pengalaman kerja, maka diasumsikan individu memiliki pemahaman yang lebih mendalam terhadap proses operasional dan sistem yang berlaku.
- b) Skor Audit Sebelumnya dimana variabel ini merujuk pada hasil penilaian audit internal dari periode sebelumnya dengan rentang skor antara 1 hingga 100. Skor yang lebih tinggi menunjukkan kualitas laporan dan kepatuhan terhadap prosedur yang lebih baik.
- c) Indikasi Fraud dimana variabel ini merupakan variabel target dalam penelitian, yang menunjukkan apakah terdapat indikasi tindakan fraud. Nilai 0 menunjukkan tidak ada indikasi fraud, sementara nilai 1 menunjukkan adanya indikasi fraud berdasarkan hasil evaluasi atau temuan terkait.

Instrumen ini disusun untuk mengumpulkan data secara kuantitatif dari karyawan di berbagai cabang perusahaan. Hasil pengisian kuesioner kemudian diubah menjadi data numerik dan dianalisis secara statistik untuk mengidentifikasi potensi risiko fraud berdasarkan dimensi Fraud Diamond. Data juga dapat

digunakan untuk membangun model prediksi fraud dengan algoritma machine learning seperti Random Forest.

2) Pra-pemrosesan Data

Data mentah dari kuisioner selanjutnya diproses agar siap digunakan dalam model pembelajaran mesin. Tahapan ini mencakup:

- a) Pembersihan data dari nilai kosong, duplikasi, dan kesalahan input.
- b) Normalisasi atau standardisasi agar setiap fitur berada dalam skala yang seragam.
- c) Pengkodean (jika ada variabel kategorikal).
- d) Labeling: menetapkan apakah data termasuk kategori fraud atau non-fraud, berdasarkan skor total atau hasil validasi pakar.

3) Seleksi Fitur (Feature Selection)

Dari seluruh data yang dikumpulkan, dilakukan seleksi fitur untuk menentukan indikator mana yang paling relevan terhadap kejadian fraud. Seleksi ini penting untuk meningkatkan performa model dan mengurangi kompleksitas pemrosesan data.

4) Pembagian Data

Data dibagi menjadi dua bagian dimana data akan di latih dan diuji, berikut datanya antara lain:

- a) Data Latih (Training Set): digunakan untuk membangun model.
- b) Data Uji (Testing Set): digunakan untuk menguji performa model.

5) Penerapan Algoritma Random Forest

Model klasifikasi dibangun menggunakan algoritma Random Forest, yaitu metode ensemble yang menggabungkan banyak pohon keputusan (decision tree).

6) Evaluasi Model

Setelah model dibangun, performa dievaluasi menggunakan data uji dan beberapa metrik, seperti:

- a) Akurasi yaitu tingkat keseluruhan prediksi benar.
- b) Precision yaitu proporsi deteksi fraud yang benar-benar fraud.
- c) Recall (Sensitivity) yaitu kemampuan model menemukan seluruh kasus fraud.

d) F1-Score yaitu keseimbangan antara precision dan recall.

7) Interpretasi dan Analisis Hasil

Tahap akhir adalah interpretasi terhadap hasil klasifikasi. Dari hasil Random Forest, ditentukan cabang-cabang yang terindikasi melakukan fraud. Selain itu, dilakukan analisis feature importance untuk mengetahui elemen mana dari Fraud Diamond (pressure, opportunity, rationalization, capability) yang paling berpengaruh dalam mendeteksi fraud. Temuan ini digunakan sebagai dasar untuk:

- a) Peningkatan sistem pengendalian internal.
- b) Identifikasi risiko fraud secara lebih dini.
- c) Penyusunan strategi pencegahan berbasis data.

Desain kerangka kerja dalam penelitian ini disusun untuk menggambarkan alur lengkap sistematis dari proses pendeteksian fraud pada setiap cabang perusahaan menggunakan algoritma Random Forest. Rancangan ini mencakup seluruh tahapan penting yang dimulai dari proses pengumpulan data, pengolahan data, pelatihan model, evaluasi, hingga interpretasi hasil klasifikasi

Penelitian ini merupakan penelitian kuantitatif dengan pendekatan deskriptif dan eksplanatori. Penelitian kuantitatif dipilih karena data yang digunakan berupa angka yang diperoleh melalui pengukuran dengan instrumen berupa kuesioner. Tujuan dari pendekatan ini adalah untuk mengetahui dan menganalisis pengaruh elemen-elemen dalam Fraud Diamond terhadap potensi kecurangan (fraud) di lingkungan kerja, khususnya pada karyawan di berbagai cabang perusahaan.

Data dikumpulkan dengan menggunakan instrumen kuesioner tertutup, yang dikembangkan berdasarkan empat elemen Fraud Diamond Theory, yaitu: Pressure, Opportunity, Rationalization, dan Capability. Setiap elemen dijabarkan ke dalam 5 pernyataan, sehingga total terdapat 20 pernyataan dalam kuesioner. Kuesioner disusun menggunakan skala Likert 5 poin, yaitu:

Table 3.5 Skala Likert

Skor	Keterangan
1	Sangat Tidak Setuju
2	Tidak Setuju
3	Netral
4	Setuju
5	Sangat Setuju

3.2. Lokasi Riset dan Sampel Data

Penelitian ini dilakukan pada perusahaan CV. SMARTINDO TELEKOM, yang memiliki beberapa cabang operasional di wilayah Sumatera Utara, Sumatera Barat, Batam dan Aceh. Perusahaan ini dipilih karena memiliki struktur organisasi yang mendukung pelaksanaan riset, serta memiliki sistem pelaporan dan operasional yang relevan untuk dianalisis dalam konteks deteksi fraud.

Riset dilakukan dengan pendekatan kuantitatif, di mana data diperoleh dari hasil pengisian kuesioner, lama bekerja dan historis data audit sebelumnya yang disusun berdasarkan empat elemen utama dalam teori Fraud Diamond, yaitu tekanan (pressure), kesempatan (opportunity), pembenaran (rationalization), dan kemampuan (capability). Instrumen kuisisioner disebarakan kepada karyawan yang bekerja di bagian keuangan, operasional, gudang, dan logistik di setiap cabang perusahaan.

Pengambilan sampel dilakukan menggunakan metode purposive sampling, yaitu pemilihan responden berdasarkan kriteria tertentu yang relevan dengan tujuan penelitian. Kriteria yang digunakan antara lain:

- a) Karyawan yang memiliki akses terhadap data laporan.
- b) Karyawan yang bekerja di cabang.
- c) Karyawan yang membawa barang perusahaan
- d) Karyawan yang bersedia mengisi kuesioner secara jujur dan anonim.
- e) Karyawan yang memiliki wewenang di cabang tersebut

Jumlah sampel yang digunakan dalam penelitian ini sebanyak 30 responden yang tersebar di 6 Cabang perusahaan. Setiap responden memberikan jawaban terhadap sejumlah indikator dari masing-masing aspek Fraud Diamond, yang kemudian diolah menjadi data numerik untuk keperluan pemodelan klasifikasi. Berikut adalah tabel data yang telah dikumpulkan:

Table 3.6 Sampel Data

ID	Pressure	Opportunity	Rationalization	Capability	Pengalaman Kerja	Skor Audit Terakhir	Indikasi Fraud
1	4	3	2	4	2	65	1
2	2	2	1	2	8	85	0
3	5	4	4	5	3	45	1
4	1	1	1	1	12	92	0
5	3	4	3	3	5	70	1
6	4	5	3	4	1	55	1
7	2	2	2	2	15	88	0

8	5	3	5	4	4	40	1
9	1	2	1	2	10	90	0
10	3	3	4	3	6	72	1
11	4	4	2	5	2	58	1
12	2	1	1	1	18	95	0
13	5	5	4	4	1	35	1
14	1	1	2	2	20	87	0
15	3	4	3	4	7	68	1
16	4	2	3	3	3	62	1
17	2	3	1	2	14	83	0
18	5	4	5	5	2	30	1
19	1	2	2	1	16	91	0
20	3	3	3	3	9	75	0
21	4	5	4	4	1	48	1
22	2	1	1	2	11	89	0
23	5	3	4	5	3	42	1
24	1	1	1	1	22	94	0
25	3	4	2	3	8	71	1
26	4	4	3	4	4	59	1
27	2	2	2	2	13	86	0

28	5	5	5	4	2	38	1
29	1	2	1	1	17	88	0
30	3	3	4	3	6	73	1

Data yang terkumpul dari kuisioner ini akan digunakan sebagai input dalam algoritma Random Forest untuk mengidentifikasi kemungkinan terjadinya fraud di setiap cabang perusahaan. Dengan demikian, lokasi riset dan sampel data yang dipilih diharapkan dapat merepresentasikan kondisi riil di lapangan serta mendukung validitas hasil penelitian

3.3. Waktu Pelaksanaan

Penelitian ini dilaksanakan secara bertahap dengan perencanaan waktu yang disusun secara rinci agar setiap proses penelitian berjalan sesuai target dan tujuan. Proses pelaksanaan dimulai dari studi literatur hingga ujian skripsi. Desain waktu pelaksanaan ini dirancang untuk mendukung kelancaran dalam pengumpulan data, penerapan algoritma Random Forest, serta analisis berdasarkan teori Fraud Diamond. Penelitian direncanakan berlangsung selama delapan bulan (Februari – Agustus 2025), dengan pembagian waktu dan kegiatan sebagai berikut:

Table 3.7 Pembagian Waktu dan Kegiatan


No.	Kegiatan Penelitian	Uraian Aktivitas	Waktu Pelaksanaan	Output
-----	---------------------	------------------	-------------------	--------

1	Studi Literatur dan Identifikasi Masalah	Mengkaji jurnal, buku, dan artikel tentang fraud, Fraud Diamond, dan Random Forest	1–15 Februari 2025	Kerangka masalah & teori
2	Penyusunan Proposal Skripsi	Menyusun latar belakang, rumusan masalah, tujuan, metodologi awal	16–31 Februari 2025	Draft proposal
3	Konsultasi dan Revisi Proposal	Konsultasi dengan dosen pembimbing dan revisi isi proposal	1–15 Maret 2025	Proposal final
4	Penyusunan dan Validasi Instrumen Kuisisioner	Menyusun kuisisioner berdasarkan indikator Fraud Diamond & uji validitas	16–28 Maret 2025	Kuisisioner terverifikasi
5	Penyebaran Kuisisioner dan Pengumpulan Data	Menyebarkan kuisisioner ke karyawan dari berbagai cabang perusahaan	1–31 Mei 2025	Dataset primer
6	Pengolahan dan Pra-pemrosesan Data	Pembersihan data, transformasi, encoding, validasi data	1–15 Juni 2025	Dataset bersih dan siap modeling

7	Pembagian Dataset & Feature Selection	Membagi data menjadi training/testing, seleksi fitur penting	16–30 Juni 2025	Dataset terstruktur
8	Pelatihan Model Random Forest	Membangun dan melatih model dengan data training	1–15 Juli 2025	Model machine learning awal
9	Evaluasi dan Optimasi Model	Mengukur akurasi, precision, recall, tuning parameter model	16–31 Juli 2025	Model optimal dan siap digunakan
10	Analisis dan Interpretasi Hasil	Menafsirkan hasil klasifikasi, analisis feature importance	1–15 Agustus 2025	Hasil analisis fraud tiap cabang
11	Penyusunan Bab IV dan Bab V	Menulis hasil dan pembahasan serta kesimpulan dan saran	16 Agustus – 10 September 2025	Draft akhir skripsi
12	Revisi dan Finalisasi Naskah Skripsi	Revisi sesuai arahan pembimbing, perapihan layout dan referensi	11–25 September 2025	Naskah skripsi final

13	Pengajuan dan Ujian Skripsi	Pendaftaran ujian, presentasi hasil penelitian, dan pertanggungjawaban	September 2025	Skripsi disidangkan
----	-----------------------------	--	----------------	---------------------

Berikut adalah diagram Gantt yang menggambarkan rencana waktu pelaksanaan penelitian skripsi berdasarkan 13 kegiatan utama dari Februari hingga September 2025 adalah sebagai berikut:



Gambar 3.1 Diagram Gantt (Rencana Waktu)